基于多源数据的公交客流规模关联分析

余 庆，雷曾翔，李玮峰*，杨东援
（同济大学道路与交通工程教育部重点实验室，上海 200092）

【摘要】分析公交客流规模的关联因素，梳理与公交客流规模有关的关联规则，有助于决策者把握整体态势、定义现状问题、细分问题类型。本文以深圳市为案例，以交通小区为分析单元，基于公交 IC 卡数据、人口数据、兴趣点数据、电子地图路径规划数据、微博签到数据等多源数据，从建成环境、人口密度、公交线网设施、交通可达性等维度，定量地表现影响公交客流规模的关联因素。通过构建决策树模型，揭示公交客流规模与关联因素间的映射关系，提取与公交客流规模有关的关联规则。研究结论为基于多源数据的公交客流规模评价方法提供了一种新的思路，也为公交线网规划提供了决策支持工具。

【关键词】城市交通；关联分析；决策树；公交客流；因子分析；多源数据
【中图分类号】U491.1+2　　**【文献标识码】**A　　**【文章编号】**1000-713X（2017）06-0058-07

Relational Analysis for Bus Passenger Volume Based on Multi-source Data

YU Qing, LEI Zengxiang, LI Weifeng*, YANG Dongyuan
(Key Laboratory of Road and Traffic Engineering, Ministry of Education, Tongji University, Shanghai 200092, China)

【Abstract】To understand key factors associated bus passenger volume can help decision makers to have an overall knowledge of current situation and properly propose existing problems. This paper took Shenzhen as a case and analyzed on transportation analysis zone level. Several factors are assumed to associate with bus passenger volume, including built environment, population density, transit accessibility, bus network density and metro-bus connection, which can be characterized through bus smart card data, population data, POI data, path planning data, Weibo check-in data and GIS data. Based on these indexes, decision trees are built to show mapping relationships and association rules between bus passenger volume and other indexes. Conclusions can be drawn that this research not only offers a new evaluation method for bus passenger volume, but also can support bus line network planning.

【Keywords】Urban traffic; Relational analysis; Decision tree; Bus passenger volume; Factor analysis; Multi-source data

0 引言

城市公交是一种高效集约化、环境友好型的交通方式，优先发展城市公共交通能够有效地缓解城市拥堵、提升居民生活品质、提高政府机关公务水平，是

收稿日期：2017-03-10　　修回日期：2017-03-29　　录用日期：2017-04-25
基金项目：国家自然科学基金（41501486，41371377，91546106）；中国博士后基金 (2015M572364)；城市空间信息工程北京市重点实验室经费重点项目 (2014101)。
作者简介：余庆（1993-），男，广东汕头人，硕士研究生；雷曾翔（1994-），男，江西九江人，硕士研究生；李玮峰（1990-），男，上海人，博士研究生；杨东援（1953-），男，教授，博士生导师。
* 通讯作者：lwf0103@gmail.com

?1994-2017 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

构建资源节约型、环境友好型社会的战略选择。对于一个城市而言，如何能让公交在其中发挥出更好的运营效果，首先需要决策者对公交的现状、不同区域公交线路存在的问题有整体把握。

现有的研究关注点大多仅限于通过公交线路自身属性指标对公交系统进行评价，对各线路（线网）进行综合评估。张彬[1]从线路布设、站点布局、车辆配置、运营组织等四个方面对公交线路优化与资源配置进行了界定。安冬冬[2]以四川省14个市县207条公交线路为数据样本，采用决策树理论，对公交服务水平评价体系进行分类挖掘，并分析挖掘结果对四川省不同环境下的各条公路线路服务水平提升的适用性，但其分析指标仅从线路、车辆、运营三个层次选取。高贺[3]采用因子分析法从线网技术、运营成本、运营效果、运营质量、服务水平以和运营能力6个维度对公交线路的运营状况做出评价。

从公交系统自身属性出发的分析模式仅能从表面分析公交运营效果，而对于不同建成环境水平、不同人流集聚情况的城市片区而言，公共交通的服务群体、营运策略、评价标准应该是截然不同的。基于现有的公交运营评价体系，无法发现公交系统所存在的内在问题与公交系统以外因素的关联性。

近年来，城市交通大数据系统开始逐步建立，海量多源数据的提供使城市中交通小区各方面属性的获取成为可能。本文利用多源数据将一个城市中各交通小区的公交客流规模与其自身基本特征建立关联分析，将公交客流规模与相关因素之间的关联概括为有限的几种类型，并基于这种关联关系对交通小区进行分类，为公交系统的整体态势、问题细分及进一步的案例剖析提供指导。

1 数据

1.1 公交刷卡数据

本文使用的公交刷卡数据由深圳大学空间信息智能感知与服务深圳市重点实验室所举办的第二届城市数据大赛提供。该数据集采集于2014年9月，包括深圳市连续6天的公交GPS数据和刷卡数据。其中，GPS数据覆盖市域范围内近500条公交线路的8471辆公交车，每辆车采样间隔大多集中在200秒以内；刷卡数据平均每天记录数达到214万条。

1.2 POI数据与新浪微博签到数据

POI（points of interests）数据是一种代表真实地理实体的点状数据，包含名称、经纬度、类别、标签等属性信息。POI数据库总共包含34870个深圳市POI数据，包括住宅区、餐饮美食、生活娱乐等243个小类。

新浪微博签到数据记录了微博用户在POI上的签到信息，提供了2014年1月1日到2015年2月2日之间深圳市域范围的POI微博签到情况，总体签到数据达到190万条，平均每天有3643个用户进行签到。

本文使用的POI数据与新浪微博签到数据由深圳大学空间信息智能感知与服务深圳市重点实验室提供。

1.3 人口数据

本研究利用WorldPop网站[4]提供的人口数据，估算了深圳市491个交通小区的人口数量。该数据集以100m×100m的栅格为空间统计单元，对深圳市第六次人口普查数据进行了统计。

1.4 电子地图路径规划数据

本研究利用百度地图Direction API接口获取电子地图路径规划数据，用于评估各交通小区的交通可达性。该数据集包含了深圳市491个交通小区之间，使用小汽车与公共交通出行的最短路径以及相应的行程时间。

1.5 轨道与公交线路地理信息数据

本文所采用的数据为2015年轨道与公交线路地理信息（GIS）数据，包含站点与线路线形信息。轨道GIS数据共计5条轨道线，118个轨道站点；公交GIS数据共计742条公交线路，5810个公交站点。

2 方法

2.1 公交客流规模及其关联因素的定量描述

关联关系分析方法对于指标选取十分敏感，添加或删除一个指标，得到的结果就可能完全不同，所以

?1994-2017 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

指标的选取十分重要。关联分析并不要求变量间的独立，但相关的变量在结果中会相互替代，造成结果难以解释，在变量选择时，应尽量选择反映不同特征的指标。所用数据与指标的关系见图 1。其中，将输入决策树的自变量分为三类，分别为公交系统特征类指标、建成环境指标、人流聚集类指标。

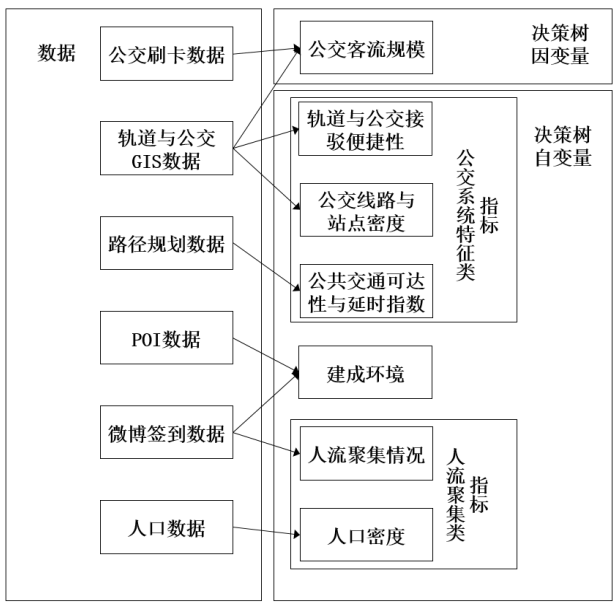

图 1　数据与具体指标的映射关系

（1）公交客流规模指标

交通小区的公交客流规模是指小区内每条线路每个站点的平均上车人次，可用于评价交通小区内新增线路站点诱增的公交服务人次。公交客流规模指标的计算方法如下：

$$B_p^i = \sum_{j=1}^{n_i} b_j / N_i \tag{1}$$

其中 B_p^i 为第 i 个小区的公交客流规模指标；N_i 为经过第 i 个小区的线路数；n_i 是第 i 个小区内公交车站数量；b_j 是交通小区内第 j 个站点上车人数。因决策树需要输入离散化的决策变量，根据计算得到结果，将公交运营效果分为四个等级：0~200 人次为 D 级，第二级为 200~400 人次为 C 级，第三级为 400~600 人次为 B 级，第四级为大于 600 人次为 A 级，各级占比均在 25% 左右。

（2）公交系统特征类指标

①可达性指标与延时指数：可达性用于反映一般出行者利用给定的交通系统从出发地点到达活动地点的便利程度，是交通系统、土地利用和出行者相互作用的关键因素。本文所用的可达性定量模型来自 Allen 1995 年提出的网络可达性模型 [5]，它主要通过平均阻隔来标识目标区域的可达性。可达性分为公交可达性与小汽车可达性，表达式为：

$$A_i = \frac{1}{n-1} \sum_{\substack{i=1 \\ j=1}}^{n} d_{ij} \tag{2}$$

其中，A_i 表示交通小区 i 采用某种交通方式的可达性指标；n 为小区总数；d_{ij} 为小区 i 与小区 j 之间采用该种交通方式的行程时间。可达性指标越大，表示该交通小区去往其他交通小区所需的时间越长，可达性越差。

同时，定义公交可达性与小汽车可达性的比值为延时指数，即：

$$\alpha_i = \frac{A_{bi}}{A_{ci}} \tag{3}$$

其中 α_i 为小区 i 的延时指数，A_{bi} 为小区 i 的公交可达性指标，A_{ci} 为小区 i 的小汽车可达性指标。延时指数越低则表示公共交通可达性与小汽车可达性相差越小，小汽车的优势相对越小。

②公交线路密度指标与线网密度：小区内公交线路长度（线网长度）与交通小区面积之比。

③公交站点密度指标：在各交通小区的边界 300m 缓冲区内的公交站点视为为该交通小区服务的轨道站点。因此该指标为小区服务的公交站点数量与小区面积之比。

④轨道与公交接驳便捷性指标：本文中，对交通小区内每个轨道站点周围 300m 内接驳的公交线路数取平均值，作为交通小区轨道站点的公交接驳便捷性。

（3）建成环境指标

建成环境是指为包括大型城市环境在内的人类活动而提供的人造环境。本文采用 POI 数据来评估每个小区的建成环境水平。在采用 POI 数据进行分析之前，因不同类型的 POI 所代表的性质不同，本文对 POI 进

?1994-2017 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

行分类讨论，并用因子分析法浓缩各类 POI 所带的信息。

表 1　交通小区建成环境评价体系的影响因素

POI 签到数量集聚水平	符号	说明
餐饮类	x_1^i	交通小区 i 单位面积内，相应类型 POI 的签到数量
公共设施类	x_2^i	
公司类	x_3^i	
购物类	x_4^i	
宾馆类	x_5^i	
娱乐类	x_6^i	

本文将 POI 分为 6 类：餐饮、公共设施、公司、购物、酒店宾馆、娱乐类。计算各类 POI 签到数量集聚情况，见表 1。对上述变量数据进行主成分法因子分析，并根据主要特征值是否超过一定阈值（0.7）从 6 个数据变量中萃取出三个公共因子，这三个主成分方差累计贡献率达到 72.096%。

为了解各因子的实际意义，本文采用 Oblimin[6] 法对因子负载矩阵进行旋转，每个因子对应的变量载荷如表 2 所示。其中，变量的载荷代表每个变量与各因子的相关系数，反映变量对于因子的重要性。

表 2　旋转后因子分析结果

POI 签到数量集聚水平	因子载荷		
	Z_1	Z_2	Z_3
餐饮类	0.836	0.089	-0.015
公共设施类	-0.022	0.843	0.092
公司类	0.004	0.060	0.989
购物类	0.528	0.515	-0.045
宾馆类	0.656	0.266	-0.011
娱乐类	0.798	-0.357	0.073

第一公共因子（Z_1）在餐饮、购物、宾馆、娱乐类 POI 签到数量集聚水平的变量上有较大的载荷，可以称为商业类建成环境因子；第二公共因子（Z_2）在公共设施、购物类 POI 签到数量集聚水平的变量上有较大的载荷，可以称为公共设施类建成环境因子；第三公共因子（Z_3）在公司类 POI 签到数量集聚水平的变量上有较大的载荷，可以称为商务类建成环境因子。三类因子的方差贡献率分别为 39.791%、17.242% 与 15.063%。三类因子的综合因子得分以及交通小区建成环境综合得分定义如下：

$$Z_i^k = \sum_j L_{ij} X_j^k \tag{4}$$

$$B_E^k = \frac{\sum_i C_i Z_i^k}{\sum_i C_i} \tag{5}$$

其中，Z_i^k 为第 k 个交通小区的第 i 个因子得分；L_{ij} 为第 i 个因子中，第 j 个变量的载荷；B_E^k 为第 k 个交通小区的建成环境综合得分；C_i 为第个 i 因子的方差贡献率。

（4）人流聚集类指标

人口密度指标：由栅格人口数据计算得到，计算方法为小区内人口总数与小区面积之比。

人流聚集情况：交通小区内 2014 年全年微博 POI 签到总数作为评价人流聚集情况的指标。

2.2　决策树算法

本文采用决策树算法对公交客流规模关联性进行分析，决策树的优点如下：

(1) 决策树易于理解和实现，便于决策者在经过专业人员简单解释后理解决策树所表达的意义。

(2) 决策树能够同时处理数据型和常规型属性，数据的准备往往是简单或者是不必要的，在多源数据的环境下能够减少数据预处理的繁复操作。

(3) 决策树是一个白盒模型，如果给定一个观察的模型，那么根据所产生的决策树很容易推出相应的逻辑表达式。便于今后在实际应用中推广，也能指引未来小范围的案例分析。

(4) 决策树在相对短的时间内能够对大型数据源做出可行且效果良好的结果，便于交通研究人员和决策者快速概略性地把握全局。

在众多决策树算法终，本文采用 CART（Classification and Regression Trees）算法 [7]。该基本思想如下：给定有训练集变量 $x_i \in R^n (i=1,...,l)$ 及类别变量 的数据集，根据训练集变量的取值不断拆分数据集，直至每条记录都（尽量）分到正确的类别。

对于连续变量，设有某一节点 m 对应的数据集Q，对于该数据集的一个分割为 $\theta=(j,t_m)$，其中 j 是训练

?1994-2017 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

集的一个属性，t_m 为分割的阈值，该分割将数据集 Q 分为两个部分 $Q_{left}(\theta)$ 和 $Q_{right}(\theta)$，满足：

$$Q_{left}(\theta)=(x,y)\,|\,\mathrm{X}_j \le t_m \tag{6}$$

$$Q_{right}(\theta)=(x,y)\,|\,\mathrm{X}_j > t_m \tag{7}$$

从而可以计算节点 m 分割后的复杂度，计算公式为：

$$G(Q,\theta)=\frac{n_{left}}{N_m}H(Q_{left}(\theta))+\frac{n_{right}}{N_m}H(Q_{right}(\theta)) \tag{8}$$

其中 H() 为计算复杂度的函数，满足当 Q 中的元素都属于同一类时，$H(Q)$ 达到最小值 0，本文中使用的是基尼系数。

选择分割 θ^*，使得：

$$\theta^*=\arg\min_{\theta} G(Q,\theta)\theta^* \tag{9}$$

将拆分后的 Q_{left} 和 Q_{right} 当作新的 Q，继续拆分，直至拆分后对于复杂度的减少 $\max_{\theta} G(Q,\theta)$ 小于 0.01 或不能再分。

相比于其它决策树算法，CART 算法采用后剪枝的方法来防止过拟合，使用交叉验证的方法估计模型的错分率，在错分率最低处进行剪枝。

3 结果与分析

3.1 建模结果

考虑到有轨道站点与无轨道站点交通小区的关联关系可能存在不同，本文对无轨道和有轨道的小区分开构建决策树，二者的差别在于是否输入轨道与公交接驳便利性指标。决策树的属性输入见图 1。决策树建模结果如图 2 和图 3 所示，对交通小区基于关联关系分类后的结果如图 4 和图 5 所示。

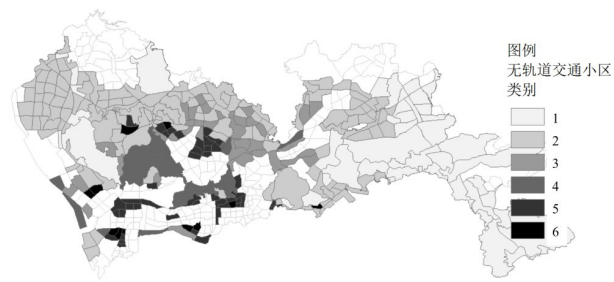

图 4 无轨道站点交通小区分类

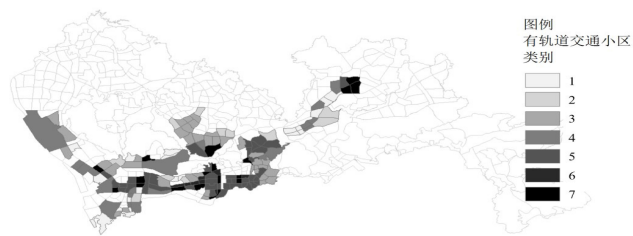

图 5 有轨道站点交通小区分类

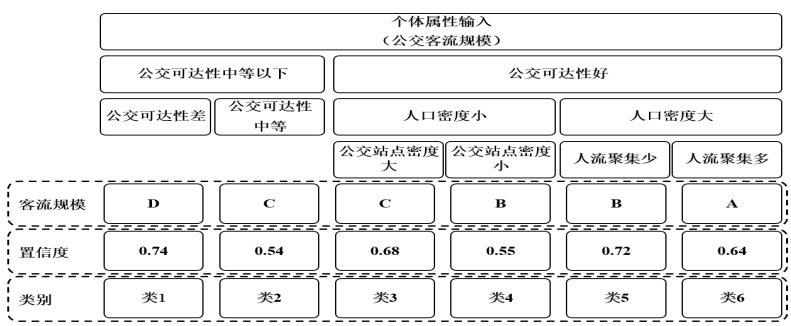

图 2 无轨道站点交通小区决策树

图 3 有轨道站点交通小区决策树

?1994-2017 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

将变量对模型复杂度减少的贡献作为变量重要性的度量，将起作用的变量按重要性进行排序，其中作用最大的变量重要度为 1，结果见表 3 和表 4。

表 3　无轨道站点的交通小区决策树变量重要性

变量	重要度
公交可达性	1
人口密度	0.28
人流聚集情况	0.13
公交站点密度	0.13

表 4　有轨道站点的交通小区决策树变量重要性

变量	重要度
轨道与公交接驳便捷性	1
人流聚集情况	0.80
延时指数	0.31
人口密度	0.28
建成环境综合评分	0.20

3.2　分析

从建模结果可见，与无轨道服务小区公交运营效果相关的因素由强到若依次为：公交可达性、人口密度、人流聚集情况、公交站点密度。与有轨道服务小区公交运营效果相关的因素由强到弱依次为：轨道与公交接驳便捷性、人流聚集情况、延时指数、人口密度和建成环境。由于指标选取时预先排除了物理意义强相关的指标，所以可以认为其他指标与小区层面的公交运营效果相关性较弱。

对比两模型可以看出，无轨道服务的小区和有轨道服务的小区影响公交客流的关键因素不同。无轨道小区中提升公交可达性是吸引公交客流的关键因素，因此对此类小区应更多考虑增加公交专用道、调整公交线路减少绕行等减少公交出行时间的措施。对于有轨道小区，轨道与公交接驳便捷性是吸引公交客流的关键因素，对于此类小区，提升公交运营效果应考虑减少轨道与公交换乘距离、增加轨道站点周边公交线路数等措施。

公交站点密度和公交线路密度两个指标在模型中的重要程度较小。在传统的公交线网规划和改善计划中往往以这两个指标评判方案的优劣，但从决策树的结果显示这一评判标准并非绝对合理。就增加公交吸引力而言，乘客更关注的是公交可达性。在考虑增加公交站点密度与公交线路密度时，需要考虑对区域公交可达性的影响。

决策树中存在一些违背常识的结果，例如：对无轨道服务的交通小区决策树中的类 3 与类 4 中，公交站点密度大的小区公交客流规模较小；有轨道服务的交通小区决策树中的类 1 与类 2 中，延时指数高的小区公交客流规模较大；类 6 与类 7 中，建成环境好的小区公交客流规模较小。对这些交通小区可以展开交通调查，将宏观的关联模型与微观案例分析相结合，以进一步分析客流规模反常的内在原因。

4　结论

大数据的出现为城市交通研究者提供了大量的数据基础，但现有对大数据的研究大多仅停留在对城市交通状态的描述上，这种层面的研究没有发挥出大数据的优势。海量多维数据的出现为分析城市公共交通问题，简化城市交通内在复杂关联性提供了新的思路。本文尝试通过利用多维数据对深圳公交客流规模关联性进行分析，并通过关联关系对交通小区进行分类。研究结果表明，通过决策树算法能够有效地将公交客流规模复杂的内在关联关系简化归纳为有限的几种类型，通过分析决策树的输出结果能够为提升公交客流规模提供辅助决策信息。在下一步的研究中，拟将对决策树中特定类型交通小区进行具体案例剖析，探索其中更深层次的内在机理，为提升城市公交系统运营效果提供政策意见。

【参考文献】

[1] 张彬 . 常规公交线路优化与资源配置评价指标体系研究 [D]. 南京：东南大学 , 2006.

[2] 安冬冬 . 基于数据挖掘技术的常规公交服务水平评价体系研究 [D]. 成都：西南交通大学 , 2015.

[3] 高贺 , 苑少伟 , 慈玉生 . 城市公交线路运营分析因子评价法 [J]. 公路交通科技 , 2014, 31(5):148-153.

[4] GeoData Institute. WorldPop[EB/OL], (2016-10-16) [2016-10-18]. http://www.worldpop.org.uk/.

[5] Pooler J A.The use of spatial separation in the measurement of transportation accessibility [J].

（下转 69 页）

?1994-2017 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

发可行性。由于是资源整合型系统，故后期维护费用基本可由各商家自行承担。通过数据分析可知用户存在强烈使用需求，且用户对于使用过程中存在的小幅广告容忍度较高，故铁路部门可在系统研发的同时进行广告招商以增加运营收入。

整体而言，系统有着极高的研发必要性与可行性，且从实用角度而言，设计运行的系统存在稳定性高以及兼容性好等优点，故可在进一步调试后投入运营。

5 结论

本文以微信平台为媒介针对到站旅客产生的住宿、娱乐、饮食等需求进行旅客到站自助服务系统设计与搭建，在提升铁路客运服务质量，优化服务末端和建立城市良好形象方面有着深远的意义。通过测试可知系统能够稳定的为到站旅客提供相应服务，且根据问卷分析可知旅客对于系统的建设持积极态度，故系统的开发与营运工作具有良好的群众基础，铁路相应部门可以适当考虑开展相应工作。

【参考文献】

[1] 王静 . 无线局域网技术在铁路车站旅客服务信息系统的应用 [D]. 成都 ：西南交通大学 , 2011.

[2] 蔡云 . 中国高速铁路旅客服务系统建设 [D]. 成都：西南交通大学 , 2012.

[3] 张稳洁 . 基于智能手机平台的铁路旅客移动服务信息系统的研究 [D]. 北京 ：首都师范大学 , 2013.

[4] 魏际洪 . 既有铁路车站旅服系统集成技术研究 [D]. 北京 ：中国铁道科学研究院 , 2016.

[5] Zhao J R, Shi X, Wei J L. Research of Reverse Logistics Information Management System Based on B/S+C/S[C]// The International Conference on E-Business and E-Government, ICEE 2010, 7-9 May 2010, Guangzhou, China, Proceedings. 2010:3403-3406.

[6] Shi Y, Gang Z, Bo A, et al. Interference Assessment in the High-Speed Railway Wireless Communication Networks by AHP-GRAP[C]// International Conference on Measuring Technology & Mechatronics Automation. IEEE Computer Society, 2013:659-662.

[7] Xu S, Zhu G, Shen C, et al. Analysis and Optimization of Resource Control in High-Speed Railway Wireless Networks[J]. Mathematical Problems in Engineering, 2014, 2014(6):1-13.

[8] Hou H A, Wang L C. A systematic approach to improve fiber-wireless access network in high speed railway tunnels[C]// IEEE International Conference on Communication Workshop. IEEE, 2015.

[9] 惠腾 . 系统分析与设计方法 [M]. 北京 ：机械工业出版社 , 2007.

[10] 方倍工作室 . 微信公众平台开发最佳实践 [M]. 北京 ：机械工业出版社 , 2014.

[11] Zhu Y J, Ke G. Research of the Store Image Based on Wechat Public Platform[J]. Applied Mechanics & Materials, 2014, 599-601:2164-2167.

责任编辑 : 杨小宝

（上接 63 页）

Transportation Research Part A Policy & Practice, 1995, 29(6): 421-427.

[6] Jackson J E.Oblimin Rotation[M].Encyclopedia of Biostatistics. 2005.

[7] Breiman, Leo.Classification and regression trees[M]. Chapman & Hall/CRC. 1984.

责任编辑 : 杨小宝

?1994-2017 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net