网络首发时间：2020-05-25 14:59:52
网络首发地址：http://kns.cnki.net/kcms/detail/11.5141.U.20200521.1714.002.html

中图分类号：U491　文献标识码：A　DOI:10.13813/j.cn11-5141/u.2020.0024

新冠肺炎疫情影响下的城际交通运输需求分析

何凌晖，余　庆，李玮峰，李　健，杨东援
(同济大学道路与交通工程教育部重点实验室，上海 201804)

摘要：运用百度迁徙数据分析新型冠状病毒肺炎疫情影响下的城际交通运输需求特征。一方面，对城际交通运输需求的时空特征进行分析，了解疫情影响下城际客流的整体趋势；另一方面，运用奇异值分解算法对城际客流的时空OD矩阵进行分解降维，对城际交通运输的客流构成进行识别。研究结果表明，疫情期间的城际交通运输包括两个阶段，节前返乡客流的趋势和规模与往年基本一致，而节后返程客流的需求释放缓慢，呈现长时间、分批次且逐步涉及疫情地区人员的特征。疫情影响下的城际交通运输需求包括四个主要类型：日常城际交通运输需求、节前返乡需求、节后返程需求和节前错峰返乡需求。其中，日常城际交通运输需求和节后返程需求受疫情影响较大。该分析方法有助于动态了解不同时期城际交通运输需求的类型构成和时空分布，为实施差异化的疫情防控策略提供定量决策依据。

关键词：城际交通；奇异值分解；时空特征；需求结构；新型冠状病毒肺炎

Inter-City Transportation Demand Under COVID-19 Pandemic

He Linghui, Yu Qing, Li Weifeng, Li Jian, Yang Dongyuan
(Key Laboratory of Road and Traffic Engineering of Ministry of Education, Tongji University, Shanghai 201804, China)

Abstract: This paper analyzes the characteristics of inter-city transportation demand during COVID-19 pandemic using Baidu migration dataset. On one hand, the spatialtemporal characteristics of inter-city transportation demand is analyzed to understand the overall trend of passenger flow under the influence of the pandemic. On the other hand, the singular value decomposition (SVD) algorithm is used to decompose and reduce the dimension of the spatiotemporal OD matrix, and identify passenger flow structure of inter-city transportation. The result shows that the inter-city transportation during the pandemic includes two stages. The trend and scale of passenger flow before the festival are basically the same as those in previous years, while the passenger flow demand after the festival increases slowly, which is long-term, in batches, and gradually involving the citizens in pandemic areas. The inter-city transportation demand under the influence of the pandemic includes four main types: normal inter-city transportation demand, returning home demand before the festival, back to work demand after the festival, and returning home demand in non-peak periods before the festival. Among them, normal inter-city transportation and back to work demand after the festival is greatly affected by the pandemic. This method can help to understand the structure and spatialtemporal distribution of inter-city transportation at different periods, and support decision-making of differential pandemic prevention and control strategies.

Keywords: inter-city transportation; singular value decomposition algorithm; spatiotemporal characteristics; demand structure; COVID-19 pandemic

收稿日期：2020-03-09
基金项目：国家重点研发计划“城市交通智能治理大数据计算平台及应用示范”(2018YFB1601100)课题三“城市交通状态‘迁移-态势演化’的敏捷预测与可靠推演”(2018YFB1601103)、同济大学学科交叉预研类重点项目“面向新型肺炎疫情的交通运输与公共安全协同智能管控关键技术”(22120200001)、国家自然科学基金青年项目“考虑有限理性出行行为的重大节假日路网应急管控方法”(71601145)
作者简介：何凌晖(1992—)，男，浙江绍兴人，在读博士研究生，主要研究方向：城市交通风险管理和应急保障。E-mail: eason_he@tongji.edu.cn
通信作者：李玮峰(1990—)，男，上海人，博士，助理研究员，主要研究方向：城市交通规划。E-mail: liweifeng@tongji.edu.cn

0 引言

2019年12月以来，湖北武汉陆续发现多起新型冠状病毒肺炎(以下简称“新冠肺炎”)病例，均诊断为病毒性肺炎或肺部感染，后引发大规模疫情。为了有效切断新冠肺炎传染途径，中国各级政府采取了一系列措施，包括取消或推迟大型公共活动、暂时停止或有限维持城市公共交通运行、停运所有跨省公共交通线路、小区封闭式管理等，通过有效隔离病患、增加物理距离、阻断病毒传播，对控制新冠肺炎疫情的蔓延起到了比较明显的作用[1]。然而，新冠肺炎的爆发恰逢中国农历新年，节前以返乡探亲为目的的大规模人口流动加剧疫情的传播和蔓延风险，而不足一个潜伏期后的节后人口回流将会再次为疫情防控带来挑战。

城际交通运输的时空差异会导致交通行为的异质性[2]。工作日和节假日的城际出行特征具有明显的时空差异性，尤其是春节等较长时间范围的节假日[3]。另外，与新冠肺炎相类似的重大突发公共卫生事件也会造成城际交通运输时空特征的变化[4]。节假日或重大突发公共卫生事件期间的交通管控政策对城际交通运输产生了影响，但是当面临节假日和重大突发公共卫生事件同时发生的情况时，对单一对象的研究无法准确判断城际交通运输需求特征。因此，有必要对节假日和重大突发公共卫生事件共同影响下的城际交通运输需求特征进行分析，主要包括城际交通运输需求的整体趋势和结构变化特征。

许多研究针对节假日或重大突发公共卫生事件对城际交通运输的影响进行了分析。对于节假日城际交通运输的研究，以往研究往往基于公路线圈数据等进行分析[5]，而“百度迁徙”等数据的出现为研究人口迁移提供了更多角度和方法。例如，文献[6]以百度、腾讯、奇虎的多源数据为基础，发现2015年春节前5天和后6天分别出现两个出行高峰，春节出现低谷，同时省级春节出行网络呈现多中心和地理聚类特征。对于重大突发公共卫生事件对城际交通运输的影响，许多研究已经证明人类移动在传染病的空间传播中起着核心作用[7-9]。受制于数据获取等因素，针对政府管控措施对人口迁移的影响研究仍较为有限，文献[4]利用2009年4月和5月的移动通信数据研究调查了墨西哥甲型H1N1流感爆发期间政府警报对个体移动的影响。

为了了解新冠肺炎疫情影响下的城际交通运输需求特征，本文利用百度迁徙数据对疫情期间的城际交通运输需求进行回顾性研究。一方面，利用2020年1月1日—2月23日的城市人口迁移规模和城市间人口迁移起讫点(OD)数据，分析疫情期间城际交通运输需求的时间特征和地理空间格局；另一方面，基于奇异值分解对城际客流的时空OD矩阵进行特征分解，对疫情期间城际交通运输的需求结构进行识别，并对不同需求的时空特征进行分析。本文的相关结论将对大规模人口流动背景下的疫情防控起到积极作用。

1 研究数据

百度迁徙数据即百度地图春节人口迁徙大数据，是百度自2014年起在春运期间推出的技术品牌项目，为业界首个以人群迁徙为主题的大数据可视化项目。百度迁徙数据以春运人口迁徙密集、中国手机渗透率高为基础，对百度拥有的定位大数据进行全样本数据处理、分析和挖掘，将数亿部手机的定位数据变化映射为人群迁徙轨迹并进行可视化，能够直观、全面地反映春运期间全国人口流动的整体情况以及城际交通运输需求的时空分布特征。本文使用的百度迁徙数据主要包括两部分：迁徙规模指数和迁徙分布数据。

迁徙规模指数主要反映指定城市 i 在指定日期 s 的城际客流规模，不同日期、不同城市间的迁徙规模指数可进行横向比较。其中，迁入指数 II_i^s 表示在指定日期 s 迁入城市 i 的客流规模，迁出指数 IO_i^s 表示在指定日期 s 迁出城市 i 的客流规模。

迁徙分布数据主要反映指定城市 i 在指定日期 s 的迁入来源地分布和迁出目的地分布。其中，迁入来源地比例 RI_{ij}^s 表示从城市 j 前往城市 i 的客流与城市 i 当天总到达客流的比值，迁出目的地比例 RO_{ij}^s 则表示从城市 i 前往城市 j 的客流与城市 i 当天总出发人口的比值。

2 疫情期间城际交通运输需求的整体趋势

本文提出城际客流规模指数和全国日城际客流规模指数总量两个特征指标对疫情期

间全国范围内的城际客流趋势进行描述。利用百度迁徙数据中迁徙规模指数和迁徙分布数据获取指定日期 s 从任意城市 i 迁至城市 j 的城际客流规模指数 Q_{ij}^{s}，

$$Q_{ij}^{s}=II_{i}^{s}\times RI_{ij}^{s}. \tag{1}$$

由此，即可建立指定日期 s 的城际客流OD矩阵 D_{s}。同时，按天对城际客流规模指数 Q_{ij}^{s} 进行求和，得到全国日城际客流规模指数总量 Z^{s}，

$$Z^{s}=\sum_{i}\sum_{j}Q_{ij}^{s}. \tag{2}$$

本文提出累积迁移净流量和人口恢复率两个特征指标对指定城市的城际客流趋势进行描述。以2020年1月1日为研究时段的起始日期，通过累积迁移净流量 V_{i}^{t} 反映指定城市 i 截至结束日期的城际客流主流方向，即

$$V_{i}^{t}=\sum_{t_0\leqslant s\leqslant t}II_{i}^{s}-\sum_{t_0\leqslant s\leqslant t}IO_{i}^{s}, \tag{3}$$

式中：t_0 和 t 分别为研究时段的起始日期和结束日期；s 为起始日期至结束日期内的指定日期；若 $V_{i}^{t}>0$，则表示该城市截至结束日期 t 的主要客流流向为净流入；若 $V_{i}^{t}<0$，则表示该城市出现了客流净流出现象。

本文通过人口恢复率 H_{i}^{T} 反映指定城市 i 在指定时段 $T=[t_1,t_2]$ 内的人口恢复情况，即

$$H_{i}^{T}=\frac{V_{i}^{t_2}-V_{i}^{t_1}}{\left|V_{i}^{t_1}\right|}\times 100\%, \tag{4}$$

若 $H_{i}^{T}>0$ 表示该城市在时段 T 内出现客流回流现象；若 $H_{i}^{T}<0$，则表示该城市在时段 T 内出现人口净流出现象。

2.1 城际交通运输需求的时间特征

为了概略性地了解疫情影响下城际交通运输需求的时间特征，本文选取典型城市计算2020年春运期间的累积迁移净流量和人口恢复率，并与2019年农历同期的特征指标进行比较(见图1)。深圳市作为珠三角的区域中心城市之一，是节前客流净流出、节后客流净流入的典型城市；赣州市作为重要的劳动力输出地，是节前客流净流入、节后客流净流出的典型城市。整体来看，城际交通运输需求以1月23日为界，分成两个不同阶段。在武汉“封城”和部分省市启动重大突发公共卫生事件一级响应之前，城际交通运输客流趋势与往年基本一致；而在1月23日之后，城际交通运输需求较往年显著降低，截至2月23日，节后人口恢复率均不到40%，受疫情影响严重的部分城市更可能呈现与往年完全相反的主要客流方向。

按天对城际客流规模指数 Q_{ij}^{s} 进行求和，得到全国日城际客流规模指数总量 Z^{s}

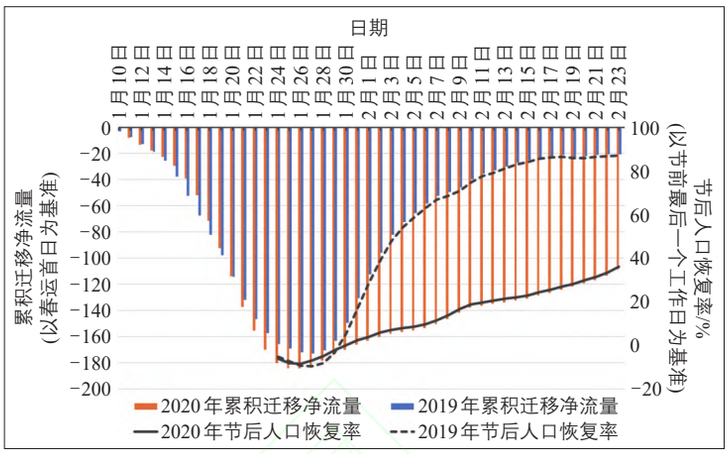

a 深圳市

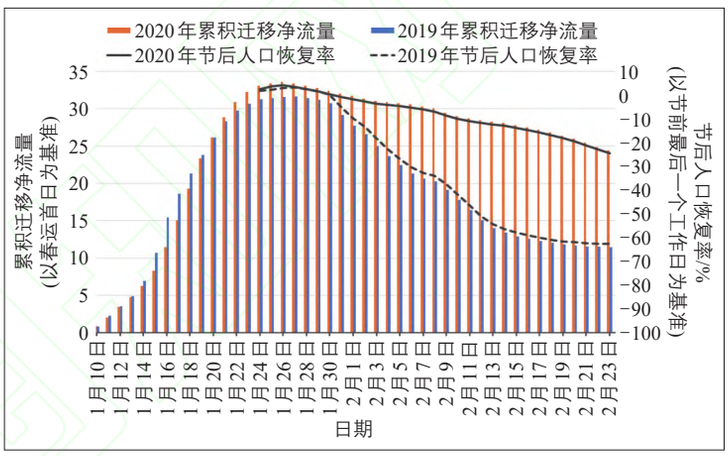

b 赣州市

注：横坐标日期为2020年公历日期，2020年农历春节是1月25日，2019年农历春节是2月5日，2019年的农历日期与2020年相对应。

图1 典型城市的城际交通运输需求时间分布

Fig.1 Temporal distribution of inter-city transportation demand in typical cities

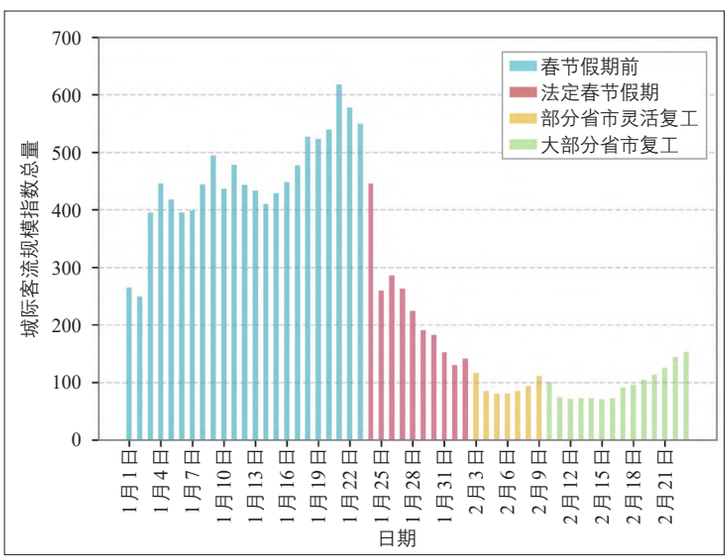

图2 城际客流规模指数总量

Fig.2 Total inter-city transportation flow index

的变化情况(见图2)。1月23日前的全国城际客流规模稳定在高位；1月23日后，法定春节假期期间城际客流规模逐日下降，至2月6日达到最低点；2月9日由于绝大部分省市开始复工，城际客流规模小幅回升，但仍维持在低位，直至2月16日后开始稳步回升。

2.2 城际交通运输需求的空间特征

根据城际交通运输需求的时间特征分析结果，本文以1月23日为关键节点，对节前返乡客流的空间格局进行分析；并以2月9日、2月16日、2月23日为关键节点，对疫情影响下节后返程客流的空间格局进行分析。

将结束日期 t 设为2020年1月23日，计算不同地级市截至节前最后一个工作日的累积迁移净流量(见图3)。图中暖色调表示该城市在节前的主要客流流向为净流入，冷色调则表示该城市在节前出现人口净流出现象。

春节前全国范围内的城际交通运输需求保持总体平衡，但从地理空间格局上来看仍存在较为明显的差异。节前的城际客流净流出集聚地主要集中在三类区域，即三大城市群(长三角城市群、京津冀城市群和珠三角城市群)、东部沿海地区以及省会城市，而河南、湖南、湖北、安徽、江西、重庆等传统的劳动力输出地则是节前客流净流入的高值区域。可以预见，春节前的客流净流入区域将是节后重要的人口输出地，在春节假期期间实施有效隔离措施是遏制节后疫情蔓延的重要手段；而春节前的客流净流出区域将是节后人口回流的主要目的地，将面临春节后复工时期预防输入型病例的重大挑战。

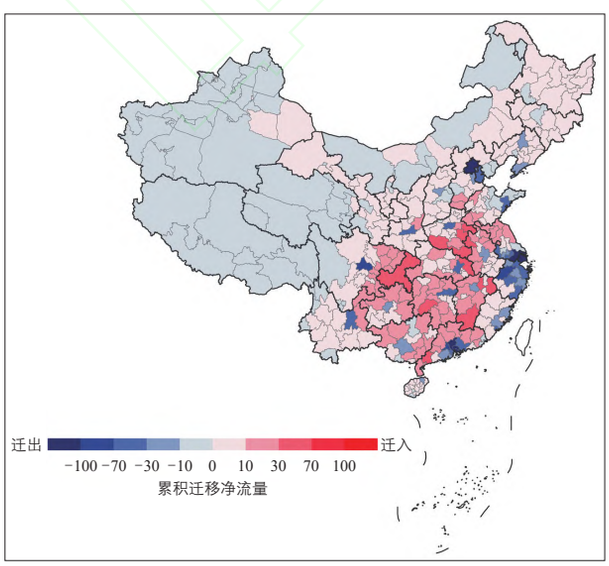

图3 春节前人口累积迁移净流量

Fig.3 Accumulated net flow of population migration before the Chinese New Year

进一步计算节后人口恢复率，反映各城市在节后的人口恢复情况。将 t_1 设为2020年1月23日，t_2 分别设为2月9日、2月16日和2月23日，分别计算节后不同时间节点相较于节前最后一个工作日的人口恢复率，得到节后各地的人口恢复情况(见图4)。图中暖色调表示该城市在春节后出现客流回流现象，冷色调则表示该城市在春节后出现客流净流出现象。

自2月9日起，全国绝大部分城市复工，部分返程客流开始逐步回流，但复工后的全国城际交通运输需求仍整体保持在低位，截至2月16日仅有约35%的城市人口恢复率超过25%。复工后半个月内，城际交通运输需求逐渐复苏，截至2月23日约有80%的城市人口恢复率超过25%，包括三大城市群和绝大部分省会城市。总体来看，截至2月23日，相较于节前的城际客流规模，节后的城际交通运输需求尚未得到充分释放，未来仍将面临较大的防疫压力。

在节前的三类客流净流出集聚地中，三大城市群和省会城市的人口恢复率较高，截至2月23日，已有约40%的节前迁出人口回流。而部分东部沿海城市由于受到疫情的影响，尚未出现明显的返程客流回流现象。节后主要的客流输出地与节前净流入区域基本吻合，但受到新冠肺炎疫情的影响，湖北以及邻近的河南、重庆、贵州和陕西等传统劳动力输出地的城际交通运输需求仍保持在低位，截至2月23日，节后输出的客流尚不及节前到达客流的25%。

3 疫情期间城际交通运输需求结构分析

3.1 基于奇异值分解的城际交通运输时空OD矩阵分解

OD矩阵是交通需求分析的基础聚合数据，通常对典型日的OD矩阵进行调查，结合社会经济和土地利用情况获得出行总数，用以分析和预测出行需求，“四阶段法”是其中经典的应用代表。其缺点是不能代表出行需求的内在结构，并且较难描述较大时空范围内的变化特征。因此，运用传统的统计方法分析OD矩阵的日变化难以解释全国范围内疫情影响下城际交通运输需求的复杂规律。随着新的数据环境的产生，移动通信数据、GPS数据等被用来连续观测人类移动需

求。与传统调查典型日OD矩阵不同，新生成的OD矩阵可以获得一段较长时间连续的OD矩阵，称为时空OD矩阵，其具备了更高维度的特征[10]。

提取时空OD矩阵的关键在于对时间维度进行压缩。由于通过简单求取数学平均值忽略了过多的时间变化特征信息，为此参照数据压缩技术，可以采用降维处理方式将高维的时空OD矩阵映射至低维空间[11]。本文使用奇异值分解的方法对连续观测获得的时空OD矩阵进行降维。

奇异值分解是一种基本的矩阵分解工具，可以将一个矩阵划分为线性不相关的多个部分，已成功应用于多个领域，包括语义分析[12]、合成材料[13]等。对2020年1月1日至2月23日的人口迁移时空OD矩阵进行奇异值分解，假设指定日期 s 的城际交通运输时空OD矩阵为 D_s，包含 n 个OD对，将 D_s 转化为 $1\times n$ 的行向量 d_s，m 天的城际客流可以表示为 $m\times n$ 的OD矩阵 M，则通过奇异值分解的方法，人口迁移时空OD矩阵可以表示为三个矩阵的乘积，即

$$M=USV^T=\sum_{h=1}^{r}\delta_h u_h v_h^T, \tag{5}$$

式中：M 是 $m\times n$ 矩阵，M 的秩是 r；U 是 $m\times r$ 的矩阵，u_h 是 U 的第 h 列，U^T 是 U 的转置矩阵；V 是 $n\times r$ 矩阵，v_h 是 V 的第 h 列，V^T 是 V 的转量矩阵；U 和 V 满足 $U^TU=E$ 和 $V^TV=E$，u_h 和 v_h 是单位向量，E 为单位矩阵；S 是对角矩阵，第 h 个对角线元素为 δ_h，即奇异值，并且 $\delta_1\geqslant\delta_2\geqslant\cdots\geqslant\delta_r$。奇异值 $\delta_h=\sqrt{\lambda_h}$，$\lambda_h$ 是 M^TM 矩阵第 h 个最大特征值，并且 $\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_r$。$u_h v_h^T$ 为 $m\times n$ 矩阵，并且秩为1。由此，人口迁移时空OD矩阵可以分解为 r 个秩为1的矩阵，奇异值 δ_h 是 M 中 $u_h v_h^T$ 的权重。

对城际交通运输时空OD矩阵进行奇异值分解的实际含义为：M 表示 r 种城际客流类型的合集，u_h 表示第 h 种城际客流的时间分布，v_h^T 表示第 h 种城际客流的空间分布，δ_h 表示第 h 种城际客流类型的重要性。在将高维的时空OD矩阵映射至低维空间的过程中，假设保留奇异值较大的 k 项 $(1\leqslant k\leqslant r)$，舍去奇异值较小的项，则得到较低维度空间的时空OD矩阵 $\hat{M}$。

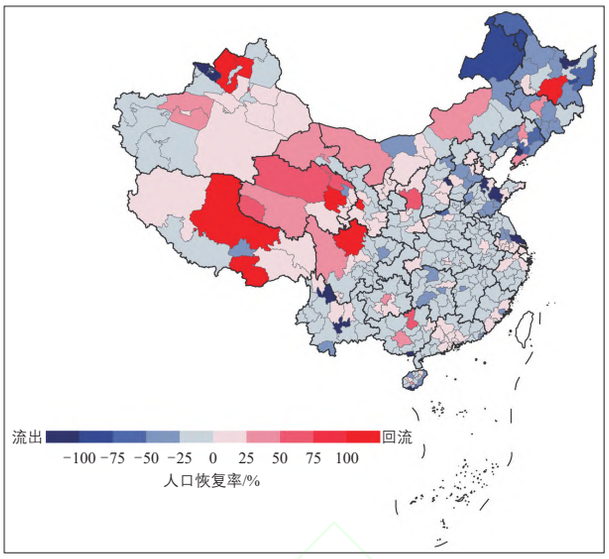

a 2月9日

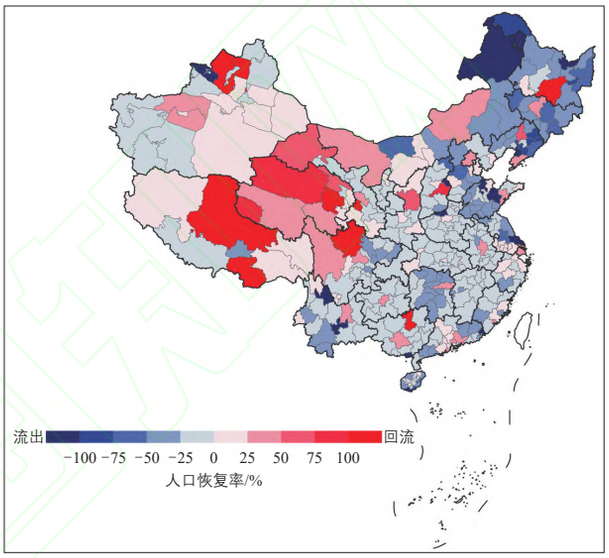

b 2月16日

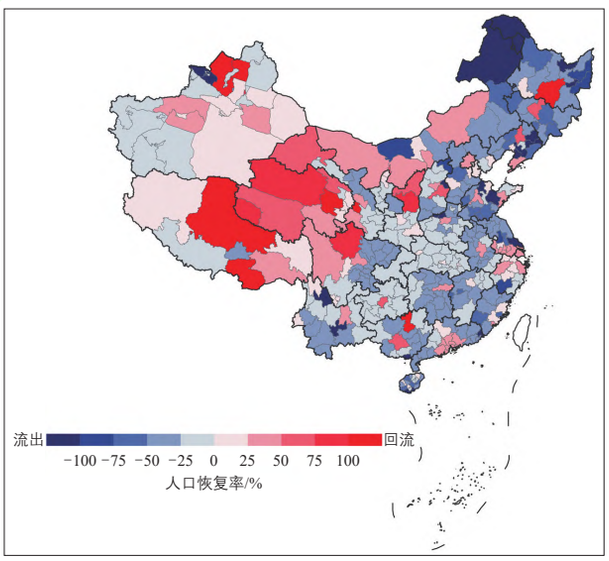

c 2月23日

图4 不同时间节点的节后人口恢复率

Fig.4 Recovery rate of mobility after the Chinese New Year at different time nodes

3.2 城际交通运输需求结构识别

通过奇异值分解对中国内地2020年1月1日—2月23日城际交通运输时空OD矩阵进行分解降维，对疫情影响下城际交通运输的需求模式和客流结构进行识别。奇异值是衡量城际交通运输时空OD矩阵各需求模式重要性的指标，奇异值越大，则对应需求模式所代表的时空OD矩阵原始信息越多。根据奇异值分布碎石图发现(见图5)，最大的奇异值数值远大于其他奇异值，且奇异值数值的下降速度很快，取最大的4项奇异值，其所对应的需求模式能够代表53.7%的时空OD矩阵原始信息，第5项奇异值后保持极小的变化幅度。

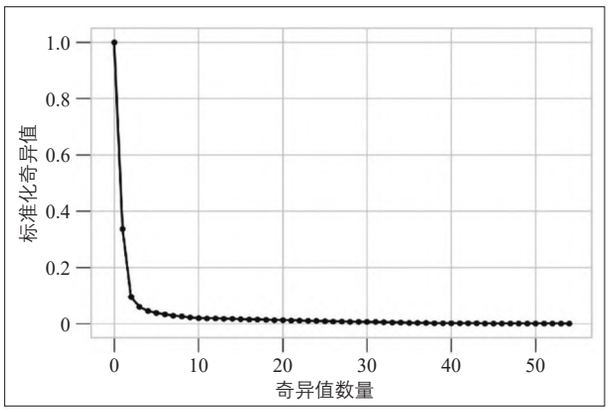

图5 城际交通运输时空OD矩阵标准奇异值分布

Fig.5 Distribution of normalized singular values of spatiotemporal OD matrix of inter-city transportation

根据奇异值数量和取值，可以从疫情影响下的城际交通运输中识别出4种较为典型的需求模式和客流类型。在图6~图9中，图a表示各类城际交通运输需求的时间单位向

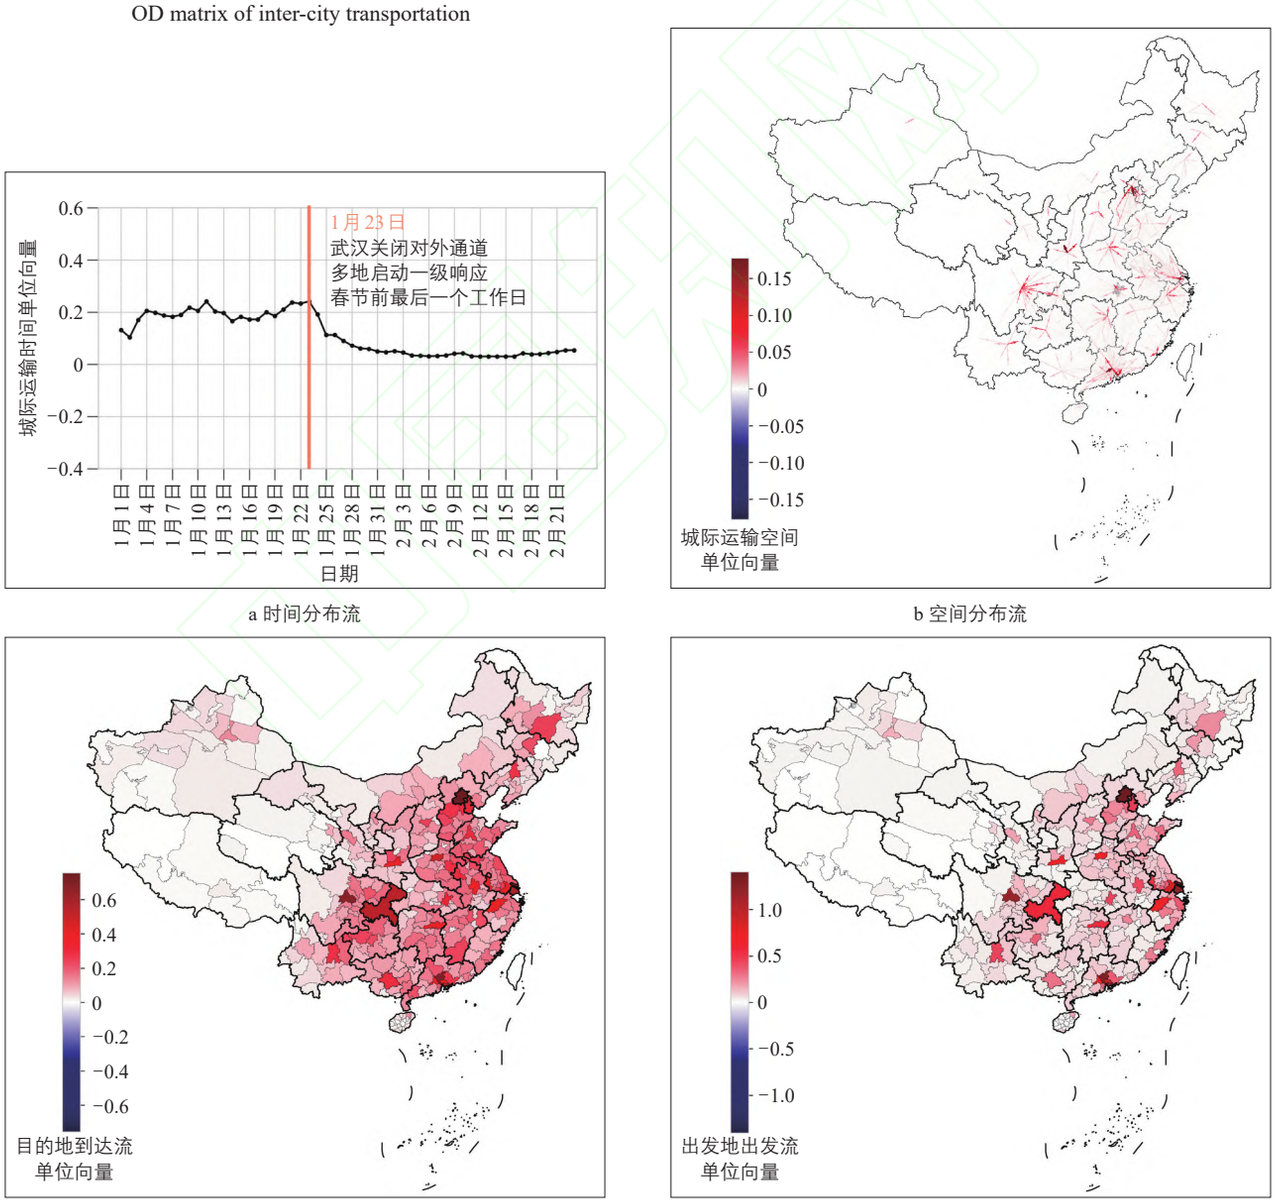

图6 客流类型I奇异值分解结果(奇异值：0.337)

Fig.6 Singular value decomposition results of type I (singular value: 0.337)

量，时间单位向量的正负对应城际交通运输需求在时间维度上的波动方向，而时间单位向量数值的绝对值则表示对应方向上的波动显著程度；图b表示各类城际交通运输需求的空间单位向量，图c、图d分别对不同城市各类型城际交通运输需求的出发量和到达量进行集计，图b~d中，暖色调表明城市的城际到发客流或OD对间的城际客流出现正向波动，冷色调表示负向波动，颜色的深浅表示对应方向上的波动显著程度。结合时间单位向量和空间单位向量观察各类型城际交通运输需求的波动情况，若某个时段内时间单位向量出现显著波动，而某个城市的到发客流或某个OD对间的城际客流存在同向的显著波动，表明该种类型需求在对应的时段和空间范围出现了显著增长；反之，时间单位向量和空间单位向量出现了异向波动，则表明该种类型需求在对应的时段和空间范围显著降低。

客流类型I代表全国城市间的日常交通运输需求。客流类型I以1月23日为界，前后两个阶段的时间流波动均较为平稳，但时间流数值由前一阶段的0.2下降至后一阶段的0.034(见图6a)。在春节长假效应和多地应对新冠肺炎疫情所采取的交通管控措施共同影响下，城市间的日常交通运输需求在短时间内下降了83%。从空间分布来看，客流类型I主要源于四大城市群(京津冀、长三角、珠三角以及成渝城市群)和绝大多数省会城市与全国其他地级市间的日常交流(见图6b~d)。

客流类型II代表节前返乡需求。自1月10日启动春运后，客流类型II的时间流在1月16日开始出现正值，至1月23日达到正

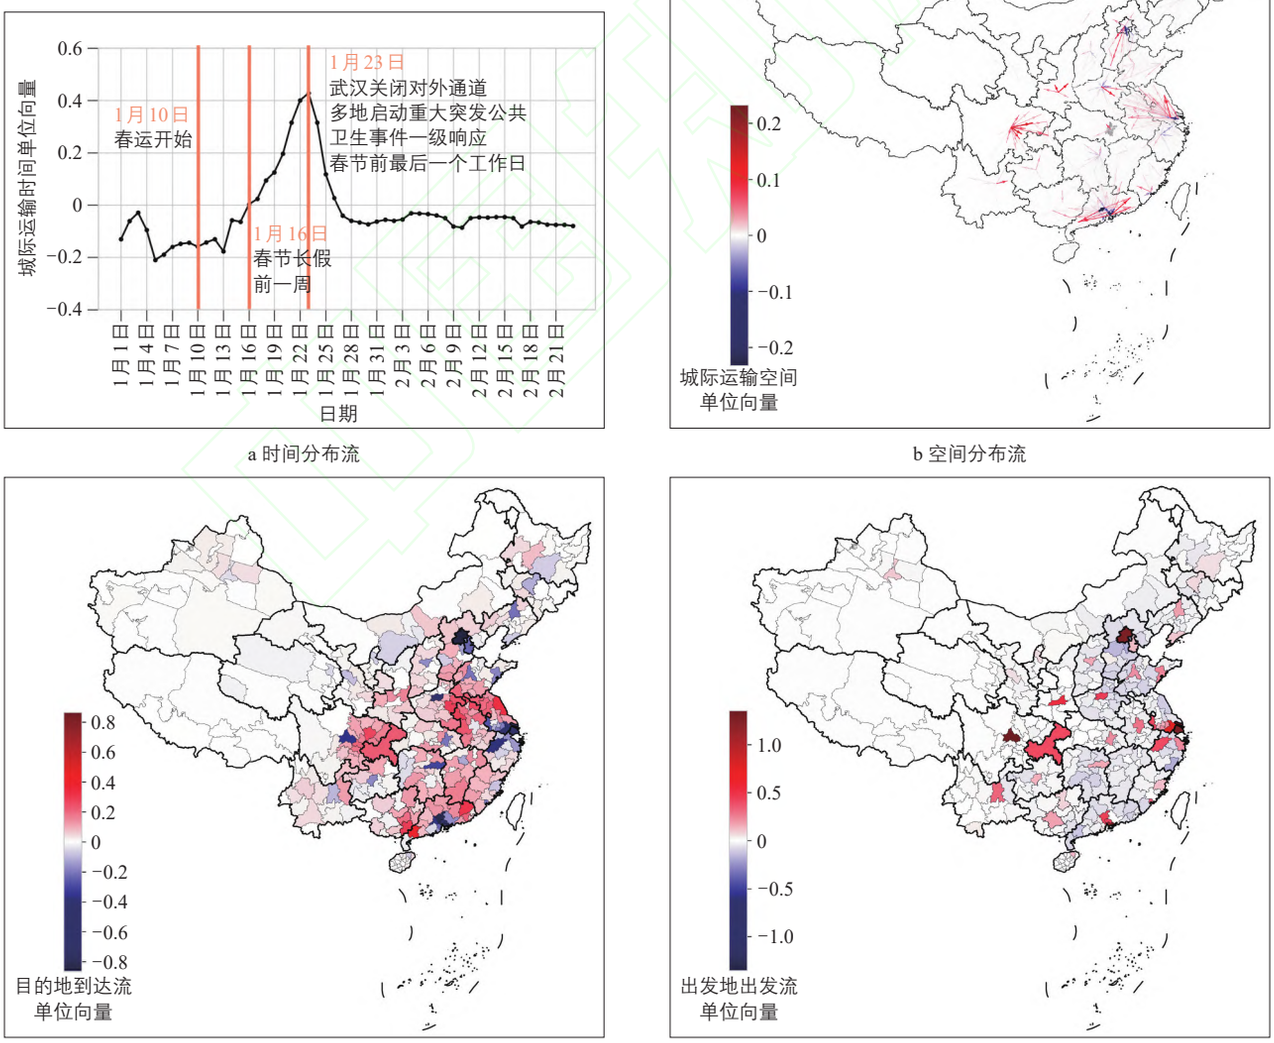

a 时间分布流　b 空间分布流

c 目的地到达流　d 出发地出发流

图7 客流类型II奇异值分解结果(奇异值：0.095)

Fig.7 Singular value decomposition results of type II (singular value: 0.095)

向最大值，并且春节长假开始后逐步下降，至1月26日后回到负值(见图7a)；在1月16—26日出现明显的正向波动，代表由于节前返乡引发的城际交通运输需求在这一时期有较为明显的增长。对应1月16—26日客流类型II的空间分布特征，结合时间和空间单位向量，节前返乡客流主要由三大城市群(京津冀、长三角、珠三角城市群)、绝大部分省会城市和东部沿海地区出发，目的地的分布呈现较为明显的层级效应和地理邻近效应(见图7b~d)。

客流类型III代表节后返程需求。客流类型III的时间流在1月24日春节长假开始后，出现了三次较为明显的正向波动，分别在1月27日、2月9日和2月23日达到三次波动的正向最大值(见图8a)。由于疫情前期交通管控措施和节后复工措施的不确定性较大，节后返程的第一次高峰较往年的返程高峰明显提前，但返程客流在1月27日国务院宣布春节假期延长后开始逐步下降。第二次返程高峰则是由于绝大部分省市宣布2月10日起正式复工，在复工前的周日达到第二次正向波动的最大值。第三次返程高峰出现在2月23日，由于研究时段的限制，第三次正向波动的持续时长和高峰时间还有待进一步的跟踪观察。从返程需求的空间分布特征来看，结合时间和空间单位向量，节后返程客流的流向与节前返乡客流流向基本相反，节前客流净流出的三大城市群(京津冀、长三角、珠三角城市群)和部分省会城市成为节后返

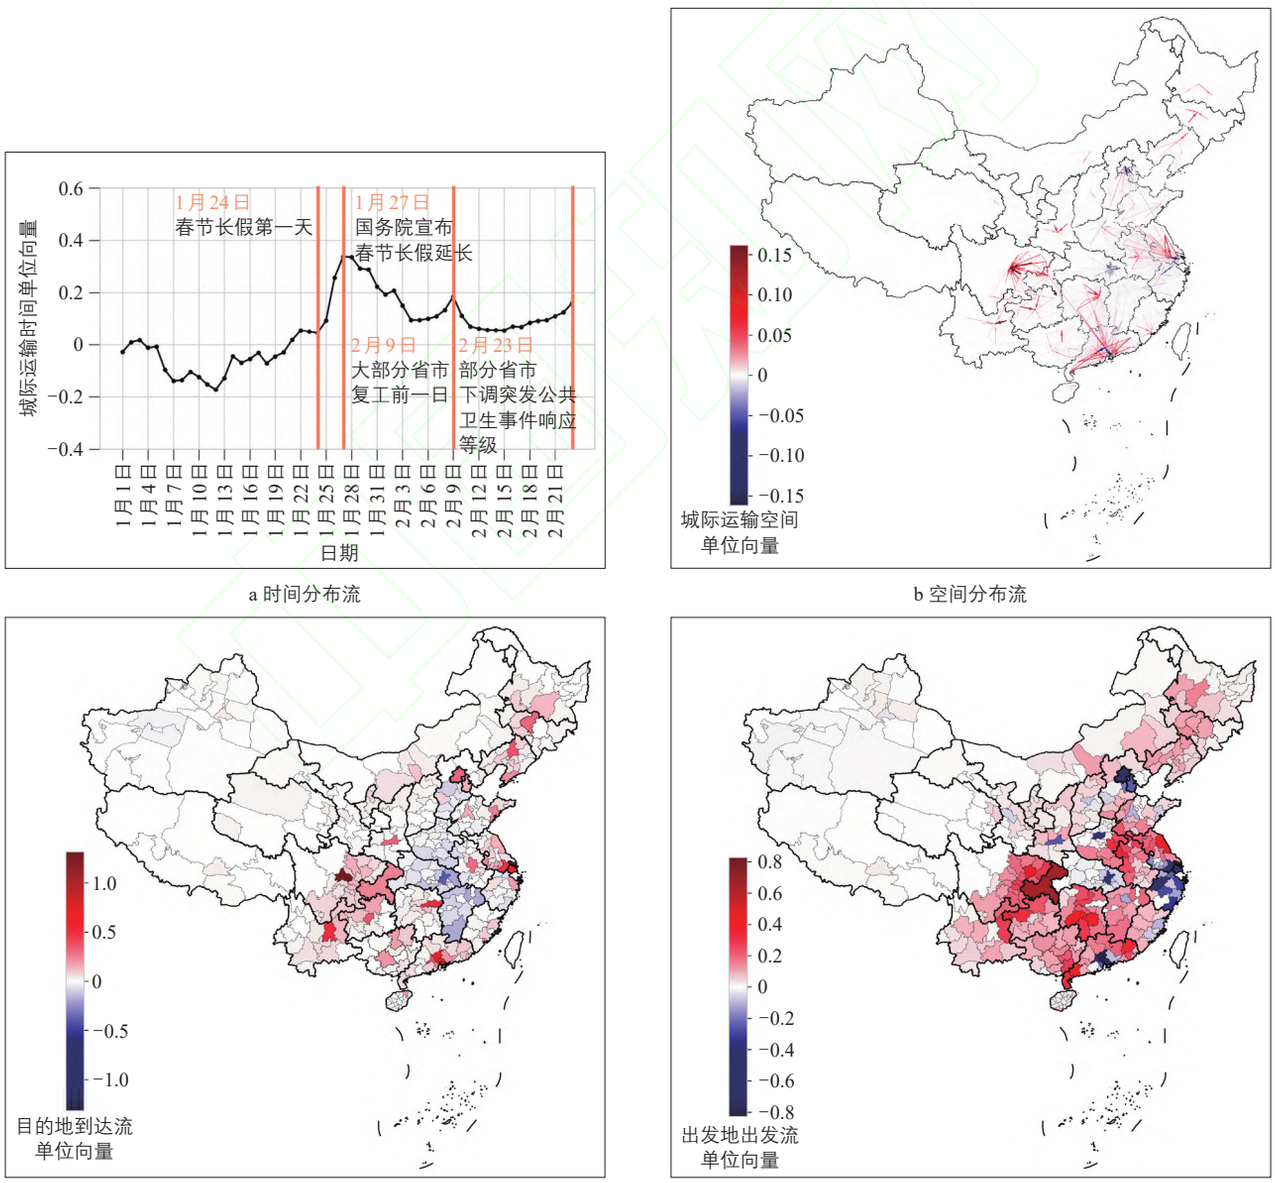

图8 客流类型III奇异值分解结果(奇异值：0.060)

Fig.8 Singular value decomposition results of type III (singular value: 0.060)

程客流的目的地(见图8b~d)。然而，受到疫情的影响，湖北省及其邻近地区的节后迁移需求增长不明显，部分东部沿海地区的返程到达需求也尚未得到释放。

客流类型IV代表在局部地区出现的错峰客流。客流类型IV在春运开始后先后出现了一次正向波动和一次负向波动。正向波动从1月13日开始，在1月18日春节前一周的周末达到正向波动的高峰，并在1月22日变回负值(见图9a)。从正向波动的空间分布特征来看，由长三角城市群和珠三角城市群出发的城际客流显著增大，客流目的地基本集中在两大城市群各自邻近的劳动力输出地。长三角城市群和珠三角城市群吸纳了大量外来劳动力，春运压力较大，该次正向波动代表了两大城市群外来劳动力提前错峰返乡的城际客流。负向波动从1月22日开始，至1月24日除夕当天达到了负向波动的高峰，并在1月27日变回正值。从负向波动的空间分布特征来看，郑州、长沙、西安、贵阳等内陆省份省会城市向邻近地级市的短途客流在除夕前后显著增大，负向波动代表了部分内陆省会城市的短途返乡需求。

四种主要的需求类型中，受到新冠肺炎疫情影响较大的主要是客流类型I和III，即城市间的日常交通运输和春节后的返程客流，客流类型II和IV的城际客流需求在疫情出现后已基本消失。在两种受疫情影响较大的客流类型中，客流类型I的奇异值远大于后三种需求类型，因此疫情对日常城际交通运输所带来的影响可能远大于对春运交通的影响。由于节前返乡客流规模较往年没有明

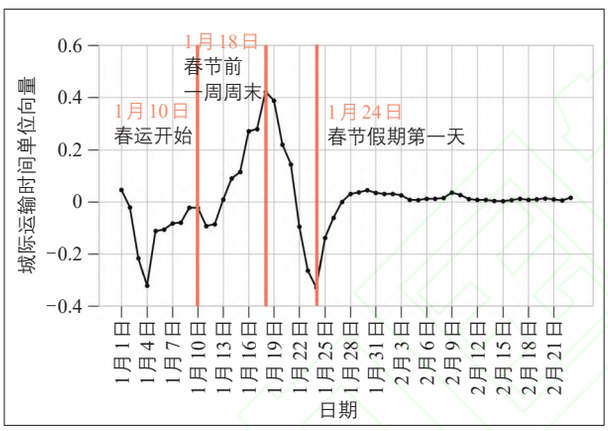

a 时间分布流

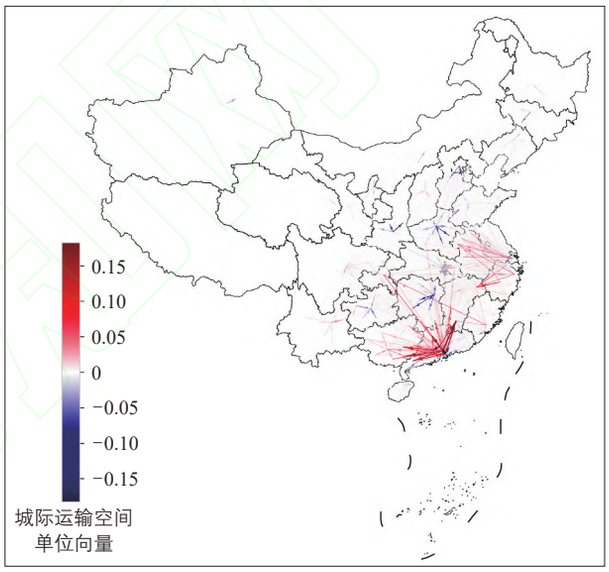

b 空间分布流

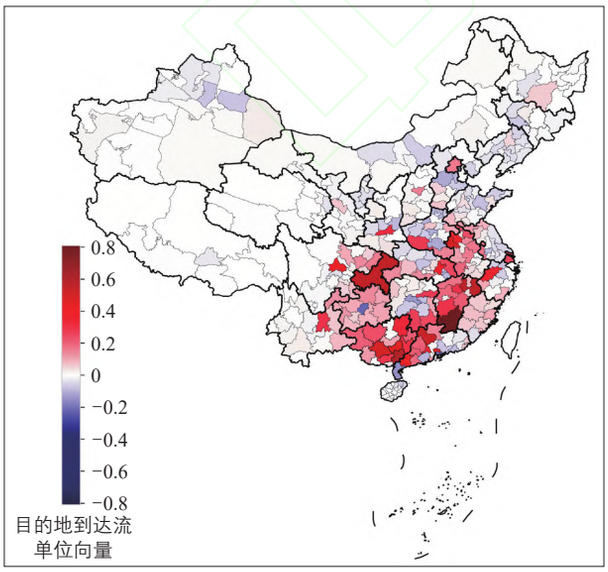

c 目的地到达流

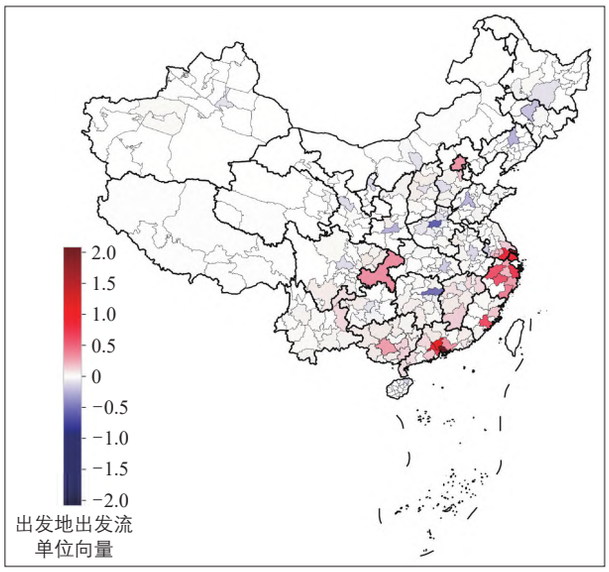

d 出发地出发流

图9 客流类型IV奇异值分解结果(奇异值：0.045)

Fig.9 Singular value decomposition results of type IV (singular value: 0.045)

显变化，而节后返程需求的释放明显放缓，因而客流类型III在疫情的影响下，将呈现持续时间较长、需求波动复杂的特点。长时间、分批次的返程需求释放以及逐渐涉及涉疫地区人员的返程需求释放将对人口流入城市的疫情防控带来较大压力。

4 结语

本文利用百度迁徙数据获取2020年1月1日—2月23日的城际人口迁移规模和迁移起讫点(OD)数据，分析疫情影响下城际交通运输需求的时间特征和地理空间格局。随后基于奇异值分解对新冠肺炎疫情影响下城际交通运输的客流类型进行识别，对疫情期间城际交通运输需求的阶段划分和阶段特征等进行分析。得到以下结论：

1）受疫情影响，春节期间的城际交通运输以1月23日为界分为两个阶段，1月23日前的城际客流规模和时空特征与往年类似，而1月23日后城际客流大幅下降，节后返程需求的释放明显放缓。这也意味着，节后将要消化与往年基本一致的返程客流，这将给疫情防控带来极大的挑战。截至2月23日，三大城市群(京津冀、长三角、珠三角城市群)和绝大部分省会城市的人口回流率不足40%，受疫情影响较大的部分东部沿海城市尚未出现人口回流现象，湖北省和邻近地区的节后返程出发客流尚未得到释放。

2）受疫情影响，城际交通运输需求可以划分为四个主要的客流类型，其中，城市间日常交通运输需求和节后返程需求受疫情影响较大，且根据奇异值大小判断，城际日常交通运输需求受到的影响大于春运交通受到的影响。长时间、分批次以及逐渐涉及涉疫地区人员的节后返程需求释放将对流入城市的疫情防控带来巨大压力。

随着春节假期的结束和新冠肺炎疫情渐趋稳定，疫情防控工作的重点将从春运期间人口大范围迁徙可能带来的跨区域疫情传播，逐渐转向疫情防控到位下的有序复工复产。为了应对节后返程需求的逐步释放、日常城际交通运输需求的逐渐恢复，下一阶段不但需要防止因复工复产引发的输入型疫情暴发，更应按照科学防控、精准施策的原则，视疫情形势保障居民正常生活和社会经济的有序恢复，减少疫情防控对低风险地区间城际人员日常往来的影响。本研究提出的方法有助于动态地了解不同时期城际交通运输需求的类型构成和时空分布，将为实施差异化的防控策略提供定量决策依据。

参考文献：

References:

[1] Cheng V, Wong S, To K, et al. Preparedness and Proactive Infection Control Measures Against the Emerging Wuhan Coronavirus Pneumonia in China[J]. Journal of Hospital Infection, 2020, 104(3): 254-255.

[2] 李涛，王姣娥，高兴川.中国居民工作日与节假日的城际出行网络异同性研究[J]. 地理学报，2020，75(4)：833-848.

[3] Tang Hong, Ou Liang. A Temporal Analysis of Holiday Effect on IP Backbone Traffic[C]//IEEE. 2017 IEEE 9th International Conference on Communication Software and Networks (ICCSN). Guangzhou: IEEE, 2017: 1042-1046.

[4] Frias-Martinez V, Rubio A, Frias-Martinez E. Measuring the Impact of Epidemic Alerts on Human Mobility[C]//PURBA 2012: 2nd Workshop on Pervasive Urban Applications, Newcastle, June 18-22, 2012.

[5] Liu Zhaobin, Sharma S. Nonparametric Method to Examine Changes in Traffic Volume Pattern During Holiday Periods[J]. Transportation Research Record, 2008(2049): 45-53.

[6] Li Jiwei, Ye Qingqing, Deng Xuankai, et al. Spatial-Temporal Analysis on Spring Festival Travel Rush in China Based on Multisource Big Data[J]. Sustainability, 2016, 8(11): 1184.

[7] Riley S. Large-Scale Spatial-Transmission Models of Infectious Disease[J]. Science, 2007, 316(5829): 1298-1301.

[8] Wesolowski A, Eagle N, Tatem A J, et al. Quantifying the Impact of Human Mobility on Malaria[J]. Science, 2012, 338(6104): 267-270.

[9] Balcan D, Colizza V, Gonçalves B, et al. Multiscale Mobility Networks and the Spatial Spreading of Infectious Diseases[J]. Proceedings of the National Academy of Sciences, 2009, 106(51): 21484-21489.

[10] Duan Zhengyu, Lei Zengxiang, Zhang M, et al. Understanding Multiple Days' Metro Travel Demand at Aggregate Level[J]. IET Intelligent Transport Systems, 2018, 13(5): 756-763.

[11] Lakhina A, Papagiannaki K, Crovella M, et al. Structural Analysis of Network Traffic Flows[J]. ACM SIGMETRICS Performance Evaluation Review, 2004, 32(1): 61−72.

[12] Deerwester S, Dumais S T, Furnas G W, et al. Indexing by Latent Semantic Analysis[J]. Journal of the Association for Information Science & Technology, 2010, 41(6): 391−407.

[13] Shahsavar A, Khanmohammadi S, Karimipour A, et al. A Novel Comprehensive Experimental Study Concerned Synthesizes and Prepare Liquid Paraffin-Fe_3O_4 Mixture to Develop Models for Both Thermal Conductivity & Viscosity: A New Approach of GMDH Type of Neural Network[J]. International Journal of Heat and Mass Transfer, 2019, 131: 432−441.